École Supérieure des Communications de Tunis
SUP'COM

Cycle ingénieur – Option CySeD – Sécurité Applicative

TupleTrace

CAHIER DES CHARGES

Plateforme sécurisée de partage de jeux de données
traçables par tatouage et empreinte numérique

Watermarking – Fingerprinting – Investigation statistique

Équipe : OMRANE Yosr, AMMAR Chaima et BEN AMOR Hayet

Encadrant : Mohamed Becha KAANICHE

Année universitaire : 2026–2027

Table des matières

1 Synthèse du projet **2**

2 Contexte et justification **3**

3 Objectifs et résultats attendus **4**

4 Périmètre et jeux de données **5**

5 Acteurs et droits d'accès **6**

6 Principe général de TupleTrace **7**

7 Module 1 : Protection et watermarking **8**

8 Module 2 : Fingerprinting et distribution **9**

9 Module 3 : Investigation et robustesse **10**

10 Catalogue initial des besoins fonctionnels **11**

11 Scénarios d'utilisation **12**

12 Architecture technique et données **13**

13 Exigences non fonctionnelles **14**

14 Tests et évaluation expérimentale **15**

15 Planning et risques **16**

1 Synthèse du projet

1.1 Présentation

TupleTrace est une application web permettant de protéger et de partager des **jeux de données tabulaires** tout en conservant une trace de leur origine et de leur distribution. Elle s'adresse aux organisations qui échangent des données tabulaires, notamment sous forme de fichiers CSV ou de tables stockées dans des bases de données relationnelles (BDR) avec des partenaires, des clients ou des chercheurs.

Le principe consiste à modifier très légèrement certaines valeurs numériques pour y dissimuler des informations vérifiables. Ces modifications doivent rester dans une marge de tolérance définie afin de ne pas compromettre l'utilité des données.

1.2 Problématique

Comment partager un jeu de données avec plusieurs destinataires, tout en pouvant reconnaître son origine et identifier la copie distribuée dont provient un extrait retrouvé, sans dégrader significativement les données ?

1.3 Les trois fonctions essentielles

— **Watermarking :** intégrer une marque commune pour établir un lien entre les données et leur propriétaire.

— **Fingerprinting :** créer une copie différente pour chaque destinataire en y ajoutant une empreinte propre à sa distribution.

— **Investigation :** analyser un extrait suspect pour rechercher ces marques et produire un résultat argumenté.

1.4 Démonstration finale visée

Un utilisateur importe un jeu de données tabulaires, choisit les colonnes pouvant être marquées, crée des copies pour plusieurs destinataires, puis soumet un extrait modifié. La plateforme tente de retrouver la marque du propriétaire et l'empreinte de la copie, avant de générer un rapport d'investigation.

Limite : retrouver la copie d'un destinataire ne prouve pas que cette personne a elle-même divulgué les données.

2 Contexte et justification

2.1 Pourquoi ce projet ?

Les organisations diffusent régulièrement des données de mesure, des statistiques, des relevés de capteurs et des résultats d'études. Une fois le fichier transmis, le propriétaire ne maîtrise plus toujours sa circulation. Un extrait peut ensuite être republié sans indication de sa provenance.

Une signature d'un fichier entier, comme un hash SHA-256, permet de reconnaître une copie *strictement identique*. En revanche, elle ne suffit pas pour retrouver l'origine d'un sous-ensemble de lignes dont certaines valeurs ont changé. TupleTrace propose de compléter cette vérification par des marques intégrées aux données elles-mêmes.

2.2 Pourquoi les données tabulaires ?

Contrairement aux images, les tables n'offrent pas de redondance visuelle. Cependant, certaines colonnes numériques peuvent tolérer de faibles écarts : température de capteur, mesure physique, score continu ou statistique approximative.

Donnée	**Exemple d'usage**
Mesures de capteurs	Un écart très faible est parfois acceptable dans la précision de l'instrument.
Statistiques numériques	La valeur reste exploitable si les moyennes et variances sont préservées.
Identifiants ou codes	Ils ne doivent pas être modifiés : une petite variation peut changer entièrement leur signification.

2.3 Intérêt métier

La plateforme est une preuve de concept de **traçabilité des données distribuées**. Elle vise une aide à l'audit et à l'investigation, et non une protection impossible à contourner ni une attribution automatique de responsabilité.

3 Objectifs et résultats attendus

3.1 Objectif général

Développer une plateforme SPA/PWA avec un backend Jakarta EE 11 permettant de tatouer des jeux de données, de produire des copies personnalisées et de rechercher leur origine après des transformations limitées.

3.2 Objectifs spécifiques

1. Importer un jeu de données tabulaires et analyser ses colonnes.
2. Définir les colonnes numériques éligibles et une tolérance de modification par colonne.
3. Insérer une marque commune de propriété sans dépasser ces tolérances.
4. Générer une empreinte différente pour chaque copie distribuée.
5. Enregistrer les destinataires et les événements de distribution.
6. Identifier une marque dans un extrait comportant moins de lignes ou des valeurs modifiées.
7. Présenter un résultat de détection avec un niveau de confiance et ses limites.
8. Tester l'application et mesurer la qualité des données et la robustesse des marques.

3.3 Résultats vérifiables

Résultat attendu	**Comment le vérifier**
Données utilisables	Les écarts restent sous les seuils fixés par colonne.
Copie individualisée	Deux destinataires reçoivent des copies portant des empreintes différentes.
Propriété détectable	Une marque commune est reconnue sur un extrait de test adapté.
Origine de copie	Le détecteur rapproche un extrait de sa distribution, lorsque les données sont suffisantes.
Application sécurisée	Les accès non autorisés et fichiers invalides sont rejetés lors des tests.

4 Périmètre et jeux de données

4.1 Fonctionnalités incluses dans le MVP

— Import et export de fichiers CSV contenant des valeurs numériques.

— Import de tables PostgreSQL sélectionnées et autorisées.

— Profilage des colonnes : types, plages, statistiques simples.

— Sélection des colonnes marquables et de leurs tolérances.

— Tatouage de propriété et empreintes personnalisées par destinataire.

— Téléchargements contrôlés et suivi des distributions.

— Investigation sur un extrait de données et génération d'un rapport.

— Simulateur de transformations et calcul des métriques de qualité.

4.2 Jeux de données retenus

La première version utilisera principalement des **données synthétiques** et des jeux de données publics adaptés : mesures de capteurs, séries de valeurs physiques ou statistiques numériques. Les données personnelles réelles sont exclues des essais.

4.3 Règles de qualité

Règle	**Description**
Colonnes éligibles	Valeurs numériques dont une faible variation est acceptable.
Colonnes interdites	Identifiants, clés, catégories, codes postaux ou valeurs exigeant une précision exacte.
Tolérance	Écart absolu ou relatif maximal validé avant insertion.
Contrôle qualité	Vérification des erreurs moyennes/maximales et de l'effet sur les statistiques.

4.4 Hors périmètre initial

Fichiers image/audio/vidéo, texte libre, données médicales identifiantes, flux continus, robustesse garantie aux jointures/agrégations et mécanismes avancés de résistance à la collusion.

5 Acteurs et droits d'accès

5.1 Acteurs principaux

Acteur	Rôle dans TupleTrace
Propriétaire de données	Importe, classe et protège ses jeux de données ; autorise leur distribution.
Gestionnaire de distribution	Prépare les copies et gère les destinataires et les autorisations.
Destinataire	Télécharge uniquement les copies qui lui sont attribuées.
Enquêteur	Soumet un extrait suspect, consulte les résultats et exporte un rapport autorisé.
Administrateur technique	Gère les comptes et le fonctionnement de la plateforme, sans accès automatique aux données métier.

5.2 Principes d'autorisation

— Chaque utilisateur possède un rôle et appartient, si nécessaire, à une organisation.

— Le backend vérifie les autorisations sur **chaque jeu de données et chaque copie**.

— Un identifiant de fichier dans l'URL ne donne aucun droit d'accès.

— Les associations entre empreintes et destinataires sont réservées aux personnes habilitées.

— Un accès révoqué empêche de nouveaux téléchargements mais n'efface pas une copie déjà obtenue.

5.3 Acteurs malveillants considérés

Le recueil SRE étudiera notamment un destinataire qui redistribue sa copie, un utilisateur qui tente d'accéder aux données d'un autre, une personne qui modifie les valeurs marquées et plusieurs destinataires qui comparent leurs copies. Ces scénarios ne sont pas des fonctionnalités destinées aux attaquants : ils servent à anticiper les risques.

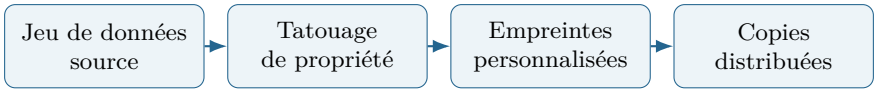
6 Principe général de TupleTrace

6.1 Deux marques complémentaires

TupleTrace insère deux informations dans des **ensembles de lignes disjoints**, afin de limiter les interférences entre les techniques.

Technique	Question	Principe
Watermarking	« À qui appartiennent ces données ? »	Marque commune à toutes les copies, associée au propriétaire.
Fingerprinting	« Quelle copie a été distribuée ? »	Marque propre à un destinataire, calculée à partir d'une sous-clé.

6.2 Parcours de traitement



Un extrait suspect pourra ensuite être soumis à un service d'investigation qui vérifie d'abord la marque commune, puis cherche une empreinte de destinataire reconnue.

6.3 Importance de la clé secrète

Les positions marquées et les bits attendus sont calculés à l'aide d'une fonction cryptographique à clé. Les clés de marquage ne sont pas publiées avec les copies. Un utilisateur qui connaît l'algorithme mais ne possède pas la clé ne doit pas pouvoir générer une empreinte authentique à volonté.

7 Module 1 : Protection et watermarking

7.1 Mission

Ce module reçoit un jeu de données, détermine quelles colonnes peuvent être modifiées et insère une **marque de propriété** compatible avec les contraintes de qualité.

7.2 Fonctionnalités

1. Importer un CSV ou sélectionner une table accessible.
2. Afficher un aperçu des colonnes, des types et des valeurs.
3. Choisir les colonnes numériques éligibles et les tolérances.
4. Calculer les positions où placer une marque à partir d'une clé secrète.
5. Insérer la marque dans des bits de faible poids des valeurs choisies, après conversion contrôlée si nécessaire.
6. Produire un rapport de qualité comparant les données initiales et marquées.
7. Conserver la référence de l'original et une empreinte SHA-256 du fichier source.

7.3 Qualité de données

Le tatouage ne doit pas modifier les identifiants de ligne ni changer une donnée catégorielle. Pour chaque colonne retenue, le propriétaire fixe une limite d'erreur. Le système refuse l'opération si cette limite ne peut être respectée.

7.4 Résultat attendu

Un jeu de données tatoué est généré avec son rapport de qualité. Les moyennes, variances et écarts maximaux peuvent être comparés au fichier source afin d'évaluer l'utilité statistique conservée.

Attention : une simple modification de bit n'est pas adaptée à toute colonne numérique. La méthode retenue devra respecter le type, l'échelle et la précision des valeurs.

8 Module 2 : Fingerprinting et distribution

8.1 Mission

Ce module crée une **copie personnalisée** pour chaque destinataire et conserve la preuve technique de la distribution.

8.2 Fonctionnement

1. Le propriétaire choisit un jeu de données protégé.
2. Le gestionnaire sélectionne les destinataires autorisés.
3. Le système génère un identifiant distinct pour chaque distribution.
4. Une sous-clé est dérivée à partir d'une clé maîtresse et de l'identifiant correspondant.
5. L'algorithme insère l'empreinte personnalisée dans les lignes réservées à cet usage.
6. Chaque copie produite est associée à un enregistrement de distribution.

8.3 Exemple conceptuel

Pour un jeu de données D, les copies sont représentées par :

$$D_i = \text{Marquer}(D, f_i), \qquad f_i \neq f_j \text{ si } i \neq j.$$

L'empreinte f_i désigne une identité de copie ; elle ne doit pas nécessairement contenir le nom du destinataire en clair.

8.4 Gestion des distributions

Le module offre des liens temporaires, des quotas de téléchargement, une révocation des accès futurs et un historique. Le registre associe la copie, le destinataire, le hash du fichier et la date de distribution. Une signature numérique peut protéger son intégrité et son authenticité.

Résultat attendu : le même fichier source donne lieu à plusieurs copies individuellement identifiables.

9 Module 3 : Investigation et robustesse

9.1 Mission

Lorsqu'un extrait de jeu de données est retrouvé, ce module cherche une marque de propriété et tente d'identifier la distribution correspondante. Une conclusion incertaine doit être annoncée comme telle.

9.2 Parcours d'investigation

1. Un enquêteur habilité importe un extrait suspect.
2. Le système vérifie le format, le schéma et les limites de taille.
3. Il repère les lignes et colonnes exploitables pour les tests.
4. Il vérifie la présence du tatouage de propriété par un test statistique.
5. Il tente de reconnaître une empreinte de destinataire parmi les distributions autorisées.
6. Il génère un rapport avec la méthode, les données exploitées, les résultats et les réserves.

9.3 Décisions possibles

Statut	**Interprétation**
Marque reconnue	L'extrait contient une marque statistiquement significative du propriétaire.
Copie identifiée	Une empreinte individuelle est reconnue et correspond à une distribution.
Indéterminé	Les données disponibles sont insuffisantes ou les tests ne sont pas concluants.
Aucune marque détectée	Aucune marque reconnue n'a été trouvée ; cela ne prouve pas son absence initiale.

9.4 Simulateur de transformations

Un banc d'essai permettra de supprimer des lignes ou des colonnes, de prélever un échantillon, d'arrondir des valeurs, d'ajouter un faible bruit ou de changer l'ordre des lignes. Le but est de **mesurer** la robustesse, pas de promettre une détection parfaite.

10 Catalogue initial des besoins fonctionnels

Les fonctionnalités sont numérotées pour être reliées au document de recueil des besoins et aux tests.

ID	Fonctionnalité
F-01	Importer un jeux de données tabulaires autorisé.
F-02	Profiler les colonnes (type, plage, statistiques).
F-03	Choisir les colonnes marquables et leurs tolérances.
F-04	Insérer le tatouage commun de propriété.
F-05	Évaluer la distorsion et produire un rapport de qualité.
F-06	Conserver les versions et le hash de l'original.
F-07	Gérer les destinataires et leurs autorisations.
F-08	Générer une copie avec empreinte propre à chaque destinataire.
F-09	Fournir des téléchargements contrôlés, temporaires et révocables.
F-10	Enregistrer et protéger les événements de distribution.
F-11	Consulter l'historique des copies et distributions.
F-12	Importer un extrait suspect en vue d'une investigation.
F-13	Rechercher la marque de propriété à l'aide d'un test statistique.
F-14	Chercher une empreinte individuelle et gérer les tests multiples.
F-15	Générer un rapport d'investigation signé.
F-16	Simuler des modifications de données sur des jeux de test.
F-17	Calculer les métriques de qualité et de robustesse.
F-18	Authentifier les utilisateurs et appliquer leurs droits d'accès.
F-19	Fournir une interface SPA/PWA avec tableaux de bord.
F-20	Journaliser les événements et vérifier l'intégrité de l'audit.

10.1 Priorités

Les fonctionnalités essentielles du MVP sont l'importation, le tatouage, la création de copies, l'investigation et la sécurité d'accès. Les améliorations de confort et les mécanismes expérimentaux avancés seront ajoutés après la validation du parcours principal.

11 Scénarios d'utilisation

11.1 Scénario A – Protéger un jeu de données

Un propriétaire connecté importe un fichier de mesures. TupleTrace détecte les colonnes numériques, propose les colonnes éligibles et affiche les tolérances. Le propriétaire confirme le marquage ; l'application crée une version protégée et son rapport de qualité.

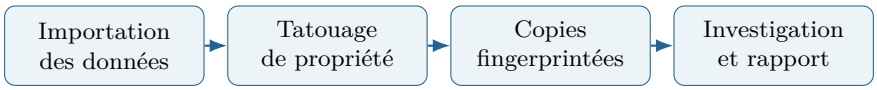
11.2 Scénario B – Distribuer des copies

Le gestionnaire sélectionne le jeu de données tatoué et trois destinataires. Le serveur génère trois copies personnalisées. Chaque copie reçoit une empreinte différente et son téléchargement est enregistré. Un destinataire ne peut pas consulter les copies des autres.

11.3 Scénario C – Enquêter sur un extrait

Un enquêteur importe un fichier contenant seulement une partie des lignes du jeu de données. L'application vérifie la présence de la marque commune, recherche une empreinte de distribution et fournit un rapport indiquant les preuves statistiques et les limites de l'analyse.

11.4 Parcours métier global



11.5 Cas d'échec

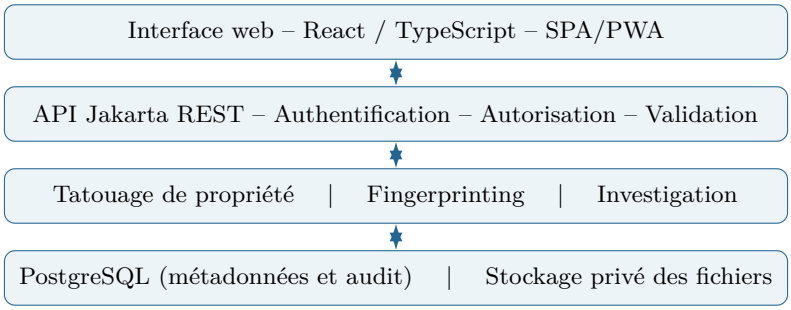
Un fichier non conforme, une tolérance incompatible ou une extraction statistiquement insuffisante doivent produire un message explicite. Aucun résultat de détection faible ne doit être présenté comme une attribution certaine.

12 Architecture technique et données

12.1 Stack technologique

Couche	Technologie retenue
Frontend	React + TypeScript, application SPA/PWA.
Backend	Jakarta EE 11 sur WildFly 42 avec Java 25.
API	Jakarta REST, validation et services métier Java.
Persistance	Jakarta Persistence (JPA) avec PostgreSQL.
Sécurité	Jakarta Security, contrôle d'accès, HMAC-SHA-256, HKDF et signatures.
Stockage	Espace privé pour les originaux et les copies.
Qualité	Tests Java, intégration continue et environnement reproductible.

12.2 Vue d'ensemble



12.3 Données principales

La base contiendra les entités **Organisation**, **Utilisateur**, **JeuDeDonnees**, **ConfigurationMarquage**, **Copie**, **Distribution**, **Investigation** et **EvenementAudit**. Les clés de tatouage et de signature seront conservées séparément des données métier.

Principe : les permissions sont contrôlées par le serveur avant chaque accès aux fichiers et aux résultats.

13 Exigences non fonctionnelles

13.1 Utilité des données

La distorsion engendrée par le tatouage doit rester dans les bornes définies par colonne. Les statistiques essentielles sont comparées avant et après le marquage.

13.2 Fiabilité

Un même jeu de test et une même configuration doivent fournir des résultats reproductibles. Les investigations doivent distinguer clairement *détection*, *non-détection* et *résultat indéterminé*.

13.3 Performance

L'application doit pouvoir traiter progressivement des fichiers de plusieurs milliers de lignes, puis être évaluée sur un jeu plus volumineux. Les traitements longs ne doivent pas bloquer l'interface. La cible de 100 000 lignes est un objectif d'essai, à mesurer sur le matériel disponible.

13.4 Ergonomie

L'interface doit proposer un parcours clair : importer, choisir les tolérances, protéger, distribuer, enquêter. Les résultats statistiques seront accompagnés d'une explication compréhensible pour un non-spécialiste.

13.5 Maintenabilité et portabilité

— Architecture modulaire et API documentées.

— Gestion des erreurs sans exposition de secrets ou de traces internes.

— Tests automatisés et historique de versions Git.

— Configuration reproductible du backend, de la base et du stockage.

— Secrets exclus du dépôt et fichiers temporaires supprimés après traitement.

13.6 Vie privée

La démonstration utilisera des données publiques ou fictives. Les destinataires et résultats d'enquête ne seront visibles que par les rôles autorisés.

14 Tests et évaluation expérimentale

14.1 Tests fonctionnels

Vérification de l'importation, du choix des colonnes, de la génération de copies, du téléchargement autorisé, de la détection et de l'exportation du rapport.

14.2 Tests de robustesse

Un simulateur réalisera des transformations contrôlées sur des copies de test :

— suppression ou échantillonnage de lignes ;

— suppression de colonnes disponibles ;

— arrondi des valeurs numériques ;

— ajout d'un faible bruit ;

— réordonnancement des lignes et colonnes.

14.3 Indicateurs

Mesure	**Ce qu'elle évalue**
Taux de détection	Part des extraits marqués effectivement reconnus.
Faux positifs	Part des extraits non marqués reconnus à tort.
Précision d'attribution	Part des copies correctement reliées à leur distribution.
Distorsion	Écarts moyens et maximaux, effet sur moyenne et variance.
Temps de traitement	Durée du tatouage et de la détection selon la taille.

14.4 Critères de recette

Le MVP est accepté si une démonstration complète fonctionne sur des données de test, que les tolérances sont respectées, que deux destinataires reçoivent des copies distinctes, qu'une copie connue peut être reconnue dans un cas expérimental documenté et qu'une copie inconnue n'est pas attribuée arbitrairement.

15 Planning et risques

15.1 Phases proposées

Phase	Travail et résultat attendu
P0	Cadrage, cahier des charges, recueil SRE et dépôt GitHub.
P1	Socle Jakarta EE, base PostgreSQL et interface SPA/PWA.
P2	Import, tatouage, contrôle qualité et copies personnalisées.
P3	Investigation, identification statistique et rapports.
P4	Tests de sécurité, audit, contrôle d'accès et résilience.
P5	Simulateur, métriques, corrections et démonstration finale.

15.2 Risques principaux

— **Données non adaptées :** choisir dès le début des colonnes numériques réellement tolérantes.

— **Petits extraits :** afficher un résultat indéterminé si les observations sont insuffisantes.

— **Altérations importantes :** mesurer la limite de robustesse sans promettre une détection systématique.

— **Complexité technique :** valider rapidement Jakarta EE 11, WildFly 42 et Java 25.

— **Temps limité :** prioriser le parcours fonctionnel complet avant les extensions.

15.3 Conclusion

TupleTrace répond aux contraintes de l'atelier en plaçant le watermarking et le fingerprinting de données tabulaires au centre d'une plateforme web sécurisée. Le projet reste réalisable sous forme d'un MVP mesurable et peut ensuite évoluer vers des recherches sur le tatouage robuste de bases de données.